

PLANO ESTRATÉGICO DO PROJETO

Desafio 03 – Titanic: Machine Learning from Disaster

InsurMinds – I2A2

Versão: 1.0

Status: Em execução

Equipe: Grupo XXXXX

Período de Desenvolvimento: 21/07/2026 a 26/07/2026

1. Introdução

Este documento apresenta o plano estratégico que será utilizado pelo grupo para o desenvolvimento do **Desafio 03 – Titanic: Machine Learning from Disaster**.

Mais do que simplesmente desenvolver um modelo capaz de prever quais passageiros sobreviveram ao naufrágio do Titanic, o grupo pretende conduzir este desafio como um projeto real de Ciência de Dados.

Nosso objetivo não será apenas obter um bom desempenho no Kaggle, mas compreender profundamente os dados, justificar tecnicamente cada decisão tomada e produzir um notebook organizado, didático e fundamentado.

O projeto será conduzido de forma colaborativa, permitindo que todos os integrantes contribuam de acordo com suas competências, independentemente do nível de conhecimento em programação.

2. Objetivo Geral

Desenvolver um modelo de Machine Learning supervisionado capaz de prever a sobrevivência dos passageiros do Titanic, seguindo as boas práticas apresentadas durante o curso e aplicando corretamente as etapas da metodologia CRISP-DM.

3. Objetivos Específicos

Durante o desenvolvimento do projeto pretendemos:

- compreender completamente o conjunto de dados;
- identificar problemas de qualidade dos dados;
- realizar uma Análise Exploratória consistente;
- formular hipóteses sobre os fatores que influenciaram a sobrevivência;
- construir novas variáveis (Feature Engineering);

- comparar modelos supervisionados;
- avaliar criticamente os resultados;
- documentar todas as decisões tomadas.

4. Nossa Filosofia de Trabalho

Este projeto será conduzido como uma investigação científica.

Isso significa que nenhuma decisão será tomada apenas porque "é uma prática comum" ou porque foi encontrada em notebooks públicos do Kaggle.

Cada etapa deverá responder três perguntas fundamentais:

O que estamos fazendo?

Por que estamos fazendo?

Como saberemos se essa decisão realmente melhorou o modelo?

Nosso notebook deverá contar uma história.

Ao final da leitura, qualquer pessoa deverá compreender não apenas qual modelo foi utilizado, mas também o caminho percorrido até a construção da solução.

5. Estratégia Geral

Nossa estratégia será baseada na metodologia **CRISP-DM**, utilizada amplamente em projetos profissionais de Ciência de Dados.

O desenvolvimento ocorrerá nas seguintes etapas:

1. Compreensão do problema.
2. Compreensão dos dados.
3. Preparação dos dados.
4. Engenharia de atributos.
5. Modelagem.
6. Avaliação.
7. Documentação dos resultados.

Cada etapa somente será iniciada após a conclusão da anterior, reduzindo retrabalho e aumentando a qualidade das análises.

6. Organização da Equipe

Nosso grupo é composto por profissionais com formações distintas.

Essa diversidade será utilizada como um diferencial do projeto.

Ao invés de concentrar todas as atividades técnicas em apenas um integrante, cada membro contribuirá utilizando sua experiência profissional.

Coordenação Técnica

Responsável por:

- organização geral do projeto;
- definição da estratégia;
- acompanhamento das atividades;
- integração dos resultados;
- revisão metodológica;
- consolidação do notebook final.

Engenharia de Dados

Responsável por:

- análise inicial do dataset;
- identificação de inconsistências;
- tratamento de dados;
- preparação das bases;
- criação das variáveis derivadas;
- apoio na implementação dos modelos.

Especialistas em Seguros

Os integrantes da área de seguros não atuarão apenas como revisores.

Sua participação será essencial durante todo o projeto.

Principais responsabilidades:

- validar hipóteses levantadas pela equipe técnica;
- interpretar os resultados obtidos;
- discutir possíveis explicações para os padrões encontrados;
- auxiliar na construção do storytelling do notebook;
- revisar a clareza das conclusões;
- contribuir para que o projeto mantenha foco no problema de negócio e não apenas nos aspectos computacionais.

Dessa forma, todos os integrantes participarão efetivamente da construção do conhecimento produzido pelo grupo.

7. Forma de Trabalho

Durante todo o projeto adotaremos uma abordagem iterativa.

Cada etapa seguirá o seguinte ciclo:

Planejar → Executar → Validar → Melhorar

Antes de iniciar uma nova atividade, verificaremos se os objetivos da etapa anterior foram realmente alcançados.

Sempre que surgirem novas descobertas durante a análise exploratória, o planejamento poderá ser ajustado.

Essa flexibilidade faz parte do processo natural de Ciência de Dados.

8. Princípios do Projeto

Durante todo o desenvolvimento seguiremos os seguintes princípios:

- simplicidade antes da complexidade;
- qualidade dos dados antes da modelagem;
- interpretação antes de otimização;
- documentação contínua;
- decisões baseadas em evidências;
- trabalho colaborativo;
- transparência metodológica;
- reprodutibilidade.

Nosso objetivo não será construir o modelo mais complexo, mas sim o modelo mais bem compreendido pela equipe.

Perfeito. Vamos manter o tom de um documento profissional, direto e objetivo.

9. Hipóteses Científicas

Antes da construção dos modelos de Machine Learning, formularemos hipóteses sobre quais características dos passageiros podem ter influenciado sua sobrevivência. Essas hipóteses orientarão a Análise Exploratória dos Dados (EDA) e servirão como base para a criação de novos atributos (Feature Engineering).

Cada hipótese será investigada utilizando evidências estatísticas e visuais.

H1 – O sexo do passageiro influencia a probabilidade de sobrevivência.

Historicamente, durante o naufrágio do Titanic, mulheres e crianças tiveram prioridade no embarque dos botes salva-vidas.

Pergunta de investigação

Existe diferença significativa entre a taxa de sobrevivência de homens e mulheres?

H2 – A idade influencia a sobrevivência.

Espera-se que crianças apresentem maior taxa de sobrevivência em relação aos adultos.

Pergunta de investigação

Existe uma faixa etária com maior probabilidade de sobrevivência?

H3 – A classe do passageiro influencia a sobrevivência.

Passageiros da primeira classe possuíam melhor localização dentro do navio e maior facilidade de acesso aos botes.

Pergunta de investigação

A classe econômica possui relação com a sobrevivência?

H4 – O tamanho da família influencia a sobrevivência.

Famílias pequenas podem ter conseguido se organizar melhor durante a evacuação, enquanto famílias muito grandes enfrentaram maiores dificuldades.

Pergunta de investigação

Existe um tamanho ideal de família associado a maiores taxas de sobrevivência?

H5 – Passageiros viajando sozinhos apresentam comportamento diferente.

Pessoas desacompanhadas podem ter reagido de maneira distinta durante a evacuação.

Pergunta de investigação

Viajar sozinho aumenta ou reduz a chance de sobrevivência?

H6 – O valor da tarifa possui relação com a sobrevivência.

Tarifas mais elevadas geralmente indicam passageiros da primeira classe.

Pergunta de investigação

Existe correlação entre o valor pago pela passagem e a sobrevivência?

H7 – O título social do passageiro pode conter informação relevante.

Os títulos presentes no nome (Mr., Mrs., Miss., Master., Dr., etc.) podem representar idade, estado civil, posição social ou profissão.

Pergunta de investigação

A extração do título social melhora o poder explicativo dos modelos?

H8 – A informação da cabine pode ser útil.

Embora muitos registros estejam ausentes, possuir uma cabine registrada pode representar passageiros com maior nível socioeconômico.

Pergunta de investigação

A existência de informação sobre cabine influencia a sobrevivência?

10. Plano de Análise Exploratória dos Dados (EDA)

A EDA será conduzida com o objetivo de compreender profundamente o comportamento das variáveis antes da construção dos modelos.

Mais do que produzir gráficos, buscamos transformar dados em conhecimento.

Cada análise deverá responder uma pergunta de negócio ou validar uma hipótese previamente formulada.

Etapa 1 – Conhecimento Geral da Base

Nesta etapa serão levantadas informações básicas do conjunto de dados:

- quantidade de registros;
- quantidade de atributos;
- tipos de dados;
- descrição das variáveis;
- identificação da variável alvo;
- identificação das variáveis categóricas e numéricas.

Etapa 2 – Qualidade dos Dados

Será realizada uma inspeção detalhada da qualidade da base.

Serão avaliados:

- valores ausentes;
- registros duplicados;
- inconsistências;
- possíveis erros de preenchimento;
- necessidade de tratamento.

O objetivo é compreender os problemas existentes antes de qualquer transformação.

Etapa 3 – Estatística Descritiva

Serão calculadas medidas descritivas das variáveis numéricas.

Entre elas:

- média;
- mediana;
- moda;
- desvio padrão;
- mínimo;
- máximo;
- quartis.

Essas informações ajudarão a identificar comportamentos anormais e possíveis outliers.

Etapa 4 – Distribuição das Variáveis

Serão analisadas as distribuições das principais variáveis utilizando gráficos apropriados.

Pretendemos identificar:

- assimetrias;
- concentração de valores;
- possíveis agrupamentos;
- comportamento geral dos dados.

Etapa 5 – Relação entre Variáveis e Sobrevivência

Esta será a etapa mais importante da EDA.

Cada hipótese definida anteriormente será investigada utilizando comparações entre as variáveis e a variável alvo (Survived).

Pretendemos responder perguntas como:

- Mulheres realmente sobreviveram mais?
- Crianças tiveram maior chance de sobrevivência?
- A primeira classe foi beneficiada?
- Passageiros sozinhos sobreviveram menos?
- Famílias grandes foram prejudicadas?

As respostas obtidas orientarão as próximas etapas do projeto.

Etapa 6 – Correlações

Serão avaliadas possíveis relações entre as variáveis numéricas.

O objetivo será identificar:

- variáveis altamente correlacionadas;
- redundâncias;
- possíveis informações complementares.

Etapa 7 – Registro dos Insights

Ao final da EDA será produzido um resumo contendo:

- principais descobertas;
- hipóteses confirmadas;
- hipóteses rejeitadas;
- novas perguntas surgidas durante a análise.

Esse registro servirá como base para a Engenharia de Features.

11. Plano de Engenharia de Atributos (Feature Engineering)

Após compreender os dados, iniciaremos a criação de novas variáveis capazes de representar melhor as características dos passageiros.

Essa etapa é considerada uma das mais importantes em projetos de Machine Learning, pois permite transformar informações existentes em atributos potencialmente mais informativos para os modelos.

Cada nova variável somente será criada caso exista uma justificativa baseada na EDA ou nas hipóteses formuladas.

Features previstas

Feature	Objetivo
FamilySize	Representar o tamanho da família do passageiro.
IsAlone	Identificar passageiros que viajavam sozinhos.
Title	Extrair títulos sociais do campo Name.
AgeGroup	Agrupar passageiros por faixas etárias.
FareGroup	Categorizar a tarifa paga.
CabinKnown	Indicar se existe informação de cabine.
Deck	Extrair o convés a partir da cabine, quando disponível.
TicketGroup	Identificar passageiros que compartilham o mesmo ticket.

Antes da implementação definitiva, cada nova variável será discutida pela equipe quanto à sua utilidade, facilidade de construção e potencial impacto na qualidade do modelo.

12. Estratégia de Modelagem

A etapa de modelagem terá como objetivo comparar diferentes algoritmos de classificação supervisionada, buscando identificar aquele que apresenta melhor equilíbrio entre desempenho e interpretabilidade.

A seleção dos modelos considerará os conteúdos abordados durante o curso, priorizando algoritmos clássicos e amplamente utilizados em problemas de classificação.

Inicialmente pretendemos avaliar:

- Regressão Logística (baseline);
- Árvore de Decisão;
- Random Forest (caso esteja alinhado ao conteúdo estudado).

Cada modelo será treinado, avaliado e comparado utilizando os mesmos dados de treinamento e validação, garantindo uma comparação justa entre os resultados.

O objetivo não será apenas identificar o modelo mais preciso, mas compreender as vantagens, limitações e comportamento de cada abordagem.

Excelente. Agora vamos concluir o documento mantendo a mesma linha técnica e objetiva.

13. Estratégia de Avaliação dos Modelos

Após o treinamento dos modelos, será realizada uma avaliação criteriosa para identificar qual abordagem apresenta o melhor equilíbrio entre desempenho, interpretabilidade e capacidade de generalização.

A comparação não será baseada exclusivamente na acurácia. Sempre que possível, outras métricas também serão analisadas para compreender o comportamento dos classificadores.

Entre os indicadores previstos estão:

- Acurácia;
- Matriz de Confusão;
- Precisão;
- Recall;
- F1-Score.

Além das métricas quantitativas, a equipe discutirá aspectos qualitativos, como:

- facilidade de interpretação do modelo;
- simplicidade de implementação;
- risco de overfitting;
- coerência entre os resultados obtidos e as hipóteses formuladas.

Nosso objetivo será selecionar um modelo que não apenas apresente bom desempenho, mas que também possa ser explicado de forma clara e fundamentada.

14. Storytelling do Notebook

O notebook será estruturado como uma investigação científica.

Ao invés de simplesmente apresentar código, o documento contará uma sequência lógica de descobertas realizadas durante o projeto.

Cada seção deverá responder naturalmente às seguintes perguntas:

Qual problema estamos investigando?

Por que esta análise é importante?

O que os dados revelam?

Que decisão foi tomada a partir dessa evidência?

Essa abordagem permitirá que qualquer leitor compreenda o raciocínio desenvolvido pelo grupo ao longo do projeto.

A estrutura prevista para o notebook será:

1. Introdução ao problema;
2. Conhecimento do conjunto de dados;
3. Formulação das hipóteses;
4. Análise Exploratória dos Dados;
5. Tratamento dos dados;
6. Engenharia de Features;
7. Construção dos modelos;
8. Comparação dos resultados;
9. Discussão;
10. Conclusões.

15. Cronograma de Execução

Considerando o prazo disponível para entrega, o grupo adotará um cronograma intensivo de desenvolvimento.

Data	Atividades
21/07	Organização do grupo, definição da estratégia, estudo do dataset e início da EDA.
22/07	Conclusão da EDA, validação das hipóteses e definição das Features.
23/07	Tratamento dos dados e implementação da Engenharia de Features.
24/07	Construção e comparação dos modelos de Machine Learning.
25/07	Refinamento do notebook, revisão dos resultados e documentação.

26/07 Revisão final, submissão ao Kaggle e entrega oficial do desafio.

Esse cronograma poderá sofrer pequenos ajustes conforme a evolução do projeto, mantendo sempre o compromisso com a entrega final.

16. Divisão Inicial das Atividades

Para aproveitar as competências da equipe, as atividades serão distribuídas conforme os perfis dos integrantes.

Coordenação Técnica

Responsabilidades:

- planejamento técnico;
- organização das atividades;
- integração do trabalho da equipe;
- consolidação do notebook;
- revisão metodológica;
- supervisão da modelagem.

Engenharia de Dados

Responsabilidades:

- exploração inicial do dataset;
- análise da qualidade dos dados;
- tratamento de valores ausentes;
- codificação das transformações;
- implementação da Engenharia de Features;
- apoio na construção dos modelos.

Especialistas em Seguros

Responsabilidades:

- discutir e validar hipóteses;
- interpretar resultados sob a ótica do negócio;
- revisar as conclusões do projeto;
- contribuir para o storytelling;
- avaliar se as interpretações fazem sentido para um profissional da área.

Essa distribuição busca garantir a participação efetiva de todos os integrantes, valorizando diferentes competências e promovendo um trabalho verdadeiramente multidisciplinar.

17. Critérios de Sucesso

Ao término do projeto consideraremos que os objetivos foram alcançados caso o grupo consiga:

- compreender profundamente o conjunto de dados;
- justificar tecnicamente todas as transformações realizadas;
- desenvolver uma Análise Exploratória consistente;
- criar atributos relevantes para o problema;
- comparar adequadamente os modelos avaliados;
- produzir um notebook claro, organizado e bem documentado;
- apresentar resultados coerentes e fundamentados.

Embora o desempenho no Kaggle seja um indicador importante, ele não será o único critério utilizado para avaliar a qualidade do trabalho desenvolvido.

18. Riscos do Projeto

Durante a execução do desafio alguns riscos podem comprometer a qualidade dos resultados.

Entre os principais destacam-se:

- prazo reduzido para desenvolvimento;
- excesso de foco na programação em detrimento da interpretação dos dados;
- criação de features sem justificativa estatística;
- overfitting durante a modelagem;
- documentação insuficiente;
- dificuldade de integração entre as atividades desenvolvidas pelos diferentes integrantes.

A equipe buscará minimizar esses riscos por meio de comunicação constante e validação conjunta das decisões técnicas.

19. Entregáveis

Ao final do projeto deverão estar concluídos os seguintes produtos:

- Notebook Jupyter organizado e comentado;
- Modelo de Machine Learning treinado e avaliado;

- Arquivo de submissão para o Kaggle;
- Documentação resumindo as principais decisões do projeto;
- Registro das hipóteses investigadas e dos principais insights obtidos.

20. Checklist Final

Antes da submissão do desafio, a equipe deverá verificar os seguintes itens:

Organização do Projeto

- Estrutura de pastas organizada.
- Base de dados validada.
- Código executando sem erros.

Análise Exploratória

- Valores ausentes analisados.
- Variáveis compreendidas.
- Hipóteses investigadas.
- Insights registrados.

Engenharia de Features

- Features justificadas.
- Transformações documentadas.
- Variáveis categóricas tratadas.
- Dados preparados para modelagem.

Modelagem

- Modelo baseline treinado.
- Modelos comparados.
- Métricas registradas.
- Melhor modelo selecionado.

Entrega

- Notebook revisado.
- Submissão ao Kaggle realizada.
- Arquivo de submissão salvo.
- Projeto revisado por toda a equipe.

21. Considerações Finais

Este plano estratégico representa o compromisso da equipe em conduzir o Desafio 03 de forma organizada, colaborativa e metodologicamente consistente.

Mais do que alcançar um bom desempenho na competição, buscamos desenvolver competências práticas em Ciência de Dados, fortalecer o trabalho multidisciplinar e consolidar um processo de investigação baseado em evidências.

Ao longo do projeto, as decisões serão fundamentadas na análise dos dados, na discussão entre os integrantes e na aplicação dos conceitos estudados durante o curso.

Espera-se que esse processo resulte não apenas em uma solução para o desafio proposto, mas também em uma experiência de aprendizado que possa servir de base para os próximos desafios e para o Projeto Final do curso.